

Veri Madenciliği Proje Raporu

Güneş Balcı
220229043
Kocaeli University
Kocaeli, Turkey

Hilmi Ege Kara
220229046
Kocaeli University
Kocaeli, Turkey

Habil Tataroğulları
220229026
Kocaeli University
Kocaeli, Turkey

Abstract—Bu çalışmada film yorumları üzerinde duygu analizi gerçekleştirilmiş ve altı farklı modelin performansı karşılaştırılmıştır: BERT, DistilRoBERTa, Support Vector Machine (SVM), Naive Bayes, Logistic Regression ve Random Forest. Çalışmada hem derin öğrenme tabanlı transformer modelleri hem de geleneksel makine öğrenmesi yaklaşımları kullanılarak farklı model türlerinin metin sınıflandırma başarıları analiz edilmiştir.

Index Terms—Text Mining, Deep Learning, Machine Learning, Transformer Models

I. GİRİŞ

Bu çalışmada, film yorumlarından duygu analizi gerçekleştirmek amacıyla altı farklı model ele alınmaktadır: BERT, DistilRoBERTa, Support Vector Machines (SVM), Naive Bayes, Logistic Regression ve Random Forest. Söz konusu modeller hem mimari açıdan hem de öğrenme paradigmaları bakımından birbirinden belirgin şekilde ayrılmaktadır. BERT ve DistilRoBERTa, büyük metin külliyatları üzerinde ön eğitimden geçirilmiş derin öğrenme tabanlı transformer modelleriyken; SVM, Naive Bayes, Logistic Regression ve Random Forest, geleneksel makine öğrenmesi yaklaşımlarını temsil etmekte ve elle mühendislik edilmiş özniteliklere dayanmaktadır.

II. PROBLEM TANIMI

Bu çalışmanın temel problemi, film yorumlarından duygu analizi yapılırken *hangi modelin ve hangi veri yapısının* daha yüksek doğruluk ve genelleme performansı sağladığının sistematik biçimde karşılaştırılmasıdır.

Daha somut ifade etmek gerekirse, çalışma iki temel soruyu yanıtlamayı hedeflemektedir:

- 1) **Model karşılaştırması:** BERT, DistilRoBERTa, SVM, Naive Bayes, Logistic Regression ve Rastgele Orman modellerinden hangisi film yorumlarındaki duyguyu daha doğru sınıflandırmaktadır?
- 2) **Veri yapısının etkisi:** Ham veri seti üzerinde farklı ön işleme stratejileri uygulanarak birden fazla veri seti türetilmiştir. Her bir veri seti yapılandırması altı model üzerinde ayrı ayrı test edilerek, ön işleme kararlarının sınıflandırma başarımına olan etkisi de karşılaştırmalı olarak incelenmektedir.

Bu iki boyutun birlikte ele alınması önemlidir çünkü bir modelin başarısı yalnızca mimarisine değil, aldığı girdi temsiline de bağlıdır. SVM, Naive Bayes, Logistic Regression ve Random Forest gibi geleneksel yöntemler, kelimelerin sıklık

bilgisine dayanan TF-IDF vektörleriyle çalışırken bağlamsal anlam ilişkilerini yakalayamamaktadır. Öte yandan BERT ve DistilRoBERTa, cümle içindeki kelimelerin birbirleriyle olan ilişkisini çift yönlü dikkat mekanizmaları aracılığıyla modelleyerek daha zengin anlam temsilleri üretmektedir.

Sonuç olarak bu çalışma; accuracy, F1 score, precision ve duyarlılık metrikleri üzerinden modellerin karşılaştırmalı analizini yaparak, film yorumu sınıflandırma görevinde en uygun model-veri yapısı kombinasyonunu belirlemeyi amaçlamaktadır.

III. VERİ SETİ

A. Veri Seti Tanımı

Bu çalışmada kullanılan veri seti [1], toplamda 46.000 örneğe sahip olup bu örneklerin yaklaşık 19.300 tanesi özgün değerlerden oluşmaktadır. Veri setinde toplam 7 sütun bulunmaktadır: *Ratings*, *Reviews*, *movie_name*, *Resenhas*, *genres*, *Description* ve *emotion*. Bu sütunlar arasında *emotion* sütunu label olarak işlev görmektedir ve sekiz farklı duygu sınıfını kapsamaktadır. çalışma kapsamında yalnızca *Reviews*, *movie_name* ve *emotion* sütunları kullanılmak üzere seçilmiştir.

B. Veri Seti Düzenlemeleri

Deneylerde kullanılan veri seti, model eğitiminden önce çeşitli ön işleme adımlarından geçirilmiştir. İlk olarak yinelenen kayıtlar veri setinden kaldırılmıştır. Ardından, yorum niteliği taşımayan ve veri içerisinde gürültü oluşturan örnekler temizlenmiştir. Son olarak metinlerde bulunan URL'ler ve duygu analizi açısından anlam ifade etmeyen diğer öğeler kaldırılarak veri seti analiz için uygun hale getirilmiştir.

Ön işleme sürecinin ardından veri seti beş farklı sürüm halinde düzenlenmiştir:

- **Sürüm 1:** Ön işleme adımları uygulanmış, ancak sınıf dağılımına herhangi bir müdahalede bulunulmamıştır.
- **Sürüm 2:** *Surprise* sınıfı veri setinden çıkarılmıştır. Daha sonra örnek sayıları düşük olan *disgust*, *fear* ve *anger* sınıflarının örnek sayıları, LLM kullanılarak sentetik veri üretimi yoluyla artırılmış ve diğer sınıflarla benzer örnek sayılarına ulaştırılmıştır.
- **Sürüm 3:** *Surprise* sınıfı veri setinden çıkarılmıştır. Ardından örnek sayıları yüksek olan *sadness*, *joy* ve *anticipation* sınıflarının örnek sayıları azaltılarak sınıflar arasındaki örnek sayısı farkı düşürülmüştür.

- **Sürüm 4:** Örnek sayıları düşük olan *surprise*, *anger*, *fear* ve *disgust* sınıfları veri setinden çıkarılmıştır. Ayrıca en yüksek örnek sayısına sahip olan *sadness* sınıfındaki verilerin yarısı kaldırılarak daha dengeli bir sınıf dağılımı elde edilmiştir.
- **Sürüm 5:** *Sadness* sınıfındaki örnek sayısı yarıya düşürülmüş ve veri setinde yalnızca *sadness* ve *joy* duyguları bırakılarak ikili sınıflandırma problemi oluşturulmuştur.

IV. YÖNTEM

Bu çalışmada dört geleneksel makine öğrenmesi modeli ve iki transformer tabanlı derin öğrenme modeli kullanılmıştır. Modeller, film yorumlarından duygu sınıflandırma performanslarını karşılaştırmak amacıyla seçilmiştir.

A. Support Vector Machine (SVM)

Support Vector Machine (SVM), sınıflar arasındaki ayrımı maksimum marjin prensibine göre gerçekleştiren denetimli öğrenme algoritmalarından biridir. Algoritma, verileri yüksek boyutlu bir özellik uzayında ayıran optimal hiper düzlemi bulmayı amaçlamaktadır [2]. Özellikle TF-IDF ile temsil edilen seyrek ve yüksek boyutlu metin verilerinde başarılı sonuçlar vermesi nedeniyle metin sınıflandırma ve duygu analizi çalışmalarında yaygın olarak kullanılmaktadır.

B. Random Forest

Random Forest, birden fazla karar ağacının oluşturduğu topluluk öğrenmesi (ensemble learning) yaklaşımıdır. Her karar ağacı eğitim verisinin farklı alt kümeleri üzerinde eğitilmekte ve nihai tahmin çoğunluk oylaması ile elde edilmektedir [3]. Rastgele özellik seçimi ve çoklu ağaç yapısı sayesinde aşırı öğrenme (overfitting) problemini azaltabilmekte ve farklı veri kümelerinde kararlı sonuçlar üretebilmektedir.

C. Lojistik Regresyon (Logistic Regression)

Lojistik regresyon analizi, (kategorik veya sürekli) bağımsız değişkenlerin iki durumlu (dichotomous) bir bağımlı değişkenle olan ilişkisini incelemek için kullanılmaktadır. Bağımlı değişkenin sürekli bir değişken olduğu doğrusal regresyon analizinden farklı olarak, belirli bir sınıfa ait olma olasılığını hesapladığı için sınıflandırma problemlerinde yaygın olarak tercih edilmektedir [6].

D. Naive Bayes

Naive Bayes (NB), olasılık teorisine dayanan ve yaygın olarak bilinen bir sınıflandırma algoritmasıdır. Basit ancak etkili yapısı sayesinde, ürün öneri sistemlerinden tıbbi teşhis süreçlerine ve otonom araçların kontrolüne kadar çok çeşitli gerçek dünya uygulamalarında kullanılabilmektedir [7]. Çalışmada metin verilerinin sınıflandırılmasındaki genel başarısı ve hızlı hesaplama avantajı sebebiyle tercih edilmiştir.

E. BERT

BERT (Bidirectional Encoder Representations from Transformers), Google tarafından geliştirilen ve transformer mimarisine dayanan ön eğitilmiş bir dil modelidir [4]. Model, metni çift yönlü olarak işleyerek bir kelimenin anlamını hem sol hem de sağ bağlamını dikkate alarak öğrenmektedir. Bu özellik sayesinde bağlamsal anlam ilişkilerini başarılı şekilde temsil edebilmekte ve doğal dil işleme görevlerinde yüksek performans göstermektedir. Bu çalışmada önceden eğitilmiş BERT modeli duygu sınıflandırma görevi için ince ayar (fine-tuning) yöntemiyle yeniden eğitilmiştir.

F. DistilRoBERTa

DistilRoBERTa, RoBERTa modelinin bilgi damıtma (knowledge distillation) yöntemi kullanılarak küçültülmüş sürümüdür [5]. Model, daha az parametre ve daha düşük hesaplama maliyeti ile çalışırken RoBERTa'nın performansının büyük bölümünü koruyabilmektedir. Bu nedenle özellikle sınırlı donanım kaynaklarında daha hızlı eğitim ve çıkarım süreçleri sunmaktadır. Çalışmada, BERT modeline daha hafif bir alternatif olarak değerlendirilmiştir.

V. SONUÇ VE KARŞILAŞTIRMA

A. En İyi Sonuçların Karşılaştırılması

Tablo I'de her modelin deneyler boyunca elde ettiği en yüksek performans değerleri gösterilmektedir. Ayrıca bu performansın hangi veri seti sürümünde elde edildiği belirtilmiştir.

Modellerin Elde Ettiği En Yüksek Performans Değerleri

Model	Veri Seti	Accuracy	Precision	Recall	F1
BERT	V1	0.68	0.60	0.57	0.68
DistilRoBERTa	V5	0.70	0.70	0.70	0.70
SVM	V5	0.74	0.74	0.74	0.74
Naive Bayes	V5	0.73	0.75	0.73	0.73
Logistic Regression	V5	0.72	0.72	0.72	0.72
Random Forest	V5	0.65	0.72	0.65	0.64

B. Ortalama Sonuçların Karşılaştırılması

Tablo II'de her modelin tüm veri seti sürümlerinde elde ettiği sonuçların ortalaması gösterilmektedir. Bu tablo, modellerin farklı veri dağılımlarına karşı genel performanslarını değerlendirmek amacıyla hazırlanmıştır.

Modellerin Tüm Veri Seti Sürümlerindeki Ortalama Performansları

Model	Accuracy	Precision	Recall	F1
SVM	0.58	0.59	0.59	0.58
BERT	0.58	0.55	0.58	0.55
Logistic Regression	0.56	0.57	0.56	0.56
Naive Bayes	0.55	0.66	0.55	0.50
Random Forest	0.54	0.60	0.54	0.50
DistilRoBERTa	0.52	0.46	0.48	0.47

Tablo I incelendiğinde, farklı veri seti sürümlerinde modellerin performanslarının veri setinin yapısına bağlı olarak büyük değişiklikler gösterdiği görülmektedir. SVM (0.74), Naive Bayes (0.73) ve Lojistik Regresyon (0.72) gibi geleneksel modeller V5 veri setinde en yüksek doğruluk ve

F1-score değerlerine ulaşmışlardır. Ancak, BERT modeli V1 veri setinde kendi en yüksek başarısını elde etmiştir. V1 sürümü, daha fazla duygu sınıfı içeren ve sınıf dağılımı açısından daha karmaşık bir yapıya sahip olduğundan, bu veri setinde elde edilen sonuçlar modellerin çok sınıflı duygu analizi problemlerindeki başarısını daha iyi yansıtmaktadır. BERT'in bu karmaşık veri setinde 0.68 doğruluk ve 0.68 F1-score değerlerine ulaşması, modelin bağlamsal bilgiyi geleneksel modellere kıyasla etkili bir şekilde öğrenebildiğini göstermektedir.



Tablo II değerlendirildiğinde ise SVM ve BERT modellerinin ortalama performanslarının (0.58 Accuracy) zirveyi paylaştığı, Lojistik Regresyon modelinin ise hemen ardından dengeli ve kabul edilebilir (0.56 Accuracy) bir performans gösterdiği görülmektedir. Naive Bayes, ortalama F1-Score değerinde (0.50) düşüş yaşasa da, ortalama Precision değerinde (0.66) dikkat çekici bir üstünlük sergilemiştir. Geleneksel modellerin (SVM, Naive Bayes, Lojistik Regresyon) sonuçlarındaki küçük çaplı üstünlüklerin büyük ölçüde sınıf sayısının azaltıldığı ve veri dağılımının daha sade hâle getirildiği sürümlerdeki yüksek başarılarından kaynaklandığı söylenebilir. Buna karşılık BERT modeli, çok sınıflı ve daha karmaşık veri setlerinde daha istikrarlı sonuçlar üretmiştir.

Elde edilen sonuçlar birlikte değerlendirildiğinde, veri setinin yapısının model seçiminde kritik bir rol oynadığı görülmektedir. Daha karmaşık, çok sınıflı ve bağlamsal analizin önemli olduğu duygu analizi problemlerinde BERT gibi transformer tabanlı modellerin tercih edilmesi uygunken; veri setinin daha dengeli, sade olduğu veya yüksek hesaplama maliyetlerinden kaçınılması gereken durumlarda SVM, Naive Bayes ve Lojistik Regresyon modellerinin oldukça rekabetçi ve güçlü alternatifler olduğu ortaya konmuştur.


REFERENCES

- [1] F. Rehman, "IMDb Movie Reviews Genres Description and Emotions," Kaggle, 2024. [Online]. Available: <https://www.kaggle.com/datasets/fahadrehman07/movie-reviews-and-emotion-dataset>
- [2] M. F. Türkoğlu, "Support Vector Machine (SVM) Algoritması-Makine Öğrenmesi," Medium, Jul. 14, 2021. [Online]. Available: <https://mfatihto.medium.com/support-vector-machine-algoritmas%C4%B1-makine-%C3%B6%C4%9Frenmesi-8020176898d8>. [Accessed: Jun. 8, 2026].
- [3] IBM, "What Is Random Forest?," IBM Think. [Online]. Available: <https://www.ibm.com/think/topics/random-forest>. [Accessed: Jun. 8, 2026].
- [4] Zeo, "BERT Algoritması Nedir? Örneklerle BERT Algoritması," [Online]. Available: <https://zeo.org/tr/kaynaklar/blog/bert-algoritmasi-nedir>. [Accessed: Jun. 8, 2026].
- [5] Sentence-Transformers, "all-distilroberta-v1", Hugging Face Model Repository. [Online]. Available: <https://huggingface.co/sentence-transformers/all-distilroberta-v1>
- [6] J. Hoffman, "Logistic Regression Analysis - an overview ScienceDirect Topics," Sciencedirect.com, 2019. <https://www.sciencedirect.com/topics/medicine-and-dentistry/logistic-regression-analysis>
- [7] I. Wickramasinghe and H. Kalutarage, "Naive Bayes: applications, variations and vulnerabilities: a review of literature with code snippets for implementation," Soft Computing, vol. 25, no. 3, pp. 2277–2293, Sep. 2020, doi: <https://doi.org/10.1007/s00500-020-05297-6>.


BERT Sürümleri




BERT Sürüm 1



BERT Sürüm 2





BERT Sürüm 3




BERT Sürüm 4

BERT Sürüm 5


DistilRoBERTa Sürümleri




DistilRoBERTa Sürüm 1



DistilRoBERTa Sürüm 2




DistilRoBERTa Sürüm 3



DistilRoBERTa Sürüm 4

DistilRoBERTa Sürüm 5

Dört Farklı Modelin Farklı Veri Setlerindeki Performans Karşılaştırması



Makine Öğrenmesi Algoritmalarının Karşılaştırması